Introdução à Ciência de Dados com Python

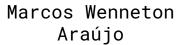








Juliany Raiol











### Ciência de Dados

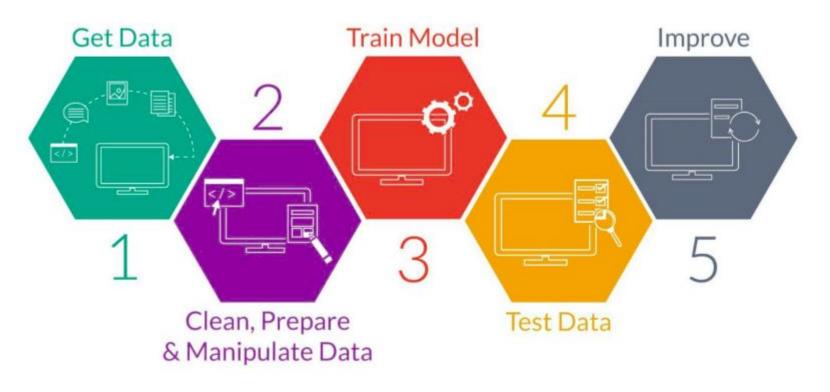
"Estudo e Análise de Dados que visa a extração de conhecimento ou *insights* para possíveis tomadas de decisão"

# Transformar um conjunto de dados

Análise de Dados

com o objetivo de poder verificá-lo melhor.

### Fluxo de trabalho do Aprendizado de Máquina



# #1 Encontrar ou Coletar um Conjunto de Dados

#### **IMDb**









460,723 images

#### Wikipedia









62,328 images



# Limpeza

	dob	photo_taken	full_path	gender	name	face location	face score	second_face_score	celeb id
0	693726	1968	[01/nm0000001_rm124825600_1899-5-10_1968.jpg]	1.0	[Fred Astaire]	[[1072.926, 161.838, 1214.783999999999, 303.6	1.459693	1.118973	6488
1	693726	1970	[01/nm0000001_rm3343756032_1899-5-10_1970.jpg]	1.0	[Fred Astaire]	[[477.184, 100.352, 622.592, 245.76]]	2.543198	1.852008	6488
2	693726	1968	[01/nm0000001_rm577153792_1899-5-10_1968.jpg]	1.0	[Fred Astaire]	[[114.96964308962852, 114.96964308962852, 451	3.455579	2.985660	6488
3	693726	1968	[01/nm0000001_rm946909184_1899-5-10_1968.jpg]	1.0	[Fred Astaire]	[[622.8855056426588, 424.21750383700805, 844.3	1.872117	NaN	6488
4	693726	1968	[01/nm0000001_rm980463616_1899-5-10_1968.jpg]	1.0	[Fred Astaire]	[[1013.8590023603723, 233.8820422075853, 1201	1.158766	NaN	6488

#### Dados Originais

# #2

# Limpeza

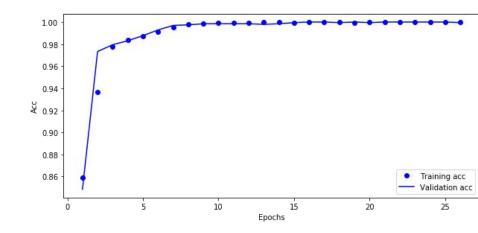
	Image_name	class_id
0	imdb/45/nm0876645_rm1932442112_1959-3-14_1999.jpg	40
1	imdb/45/nm1295245_rm2855187968_1985-3-16_2011.jpg	26
2	imdb/56/nm0005256_rm858435072_1971-4-28_2012.jpg	41
3	imdb/32/nm0852132_rm676826112_1971-7-30_2004.jpg	33
4	imdb/27/nm0001427_rm3004406528_1963-6-17_2000.jpg	37

# Dados a serem utilizados

# #3

### Treinar

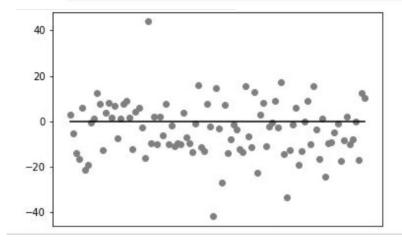
			18.50% [37/200 1:07:32<			
epoch	train_loss	valid_loss	accuracy	f_beta	time	
0	0.587283	0.462057	0.832049	0.832049	01:49	
1	0.430720	0.341835	0.864920	0.864920	01:51	
2	0.374721	0.434729	0.845917	0.845917	01:50	
3	0.337999	0.273992	0.891628	0.891628	01:50	
4	0.314837	0.426782	0.848998	0.848998	01:50	
5	0.300933	0.263492	0.888033	0.888033	01:51	

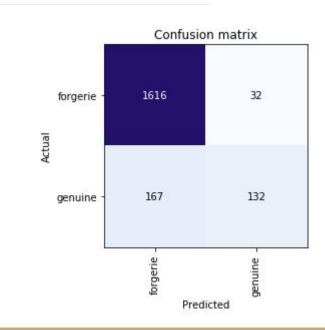




### Testar

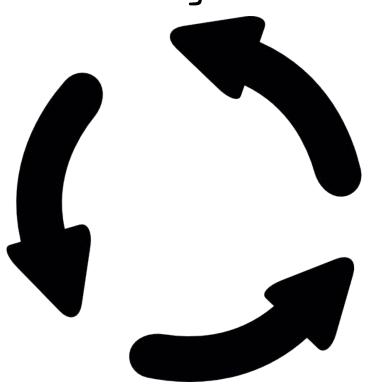
```
In [19]: fig = df_results.plot(x=df_results.index, y='Zero', color='black')
fig.axes.scatter(x=df_results.index, y=df_results['Ŷ Previsto - Y Real'],color='grey')
fig.axes.get_xaxis().set_visible(False)
fig.axes.get_legend().set_visible(False)
```





# #5

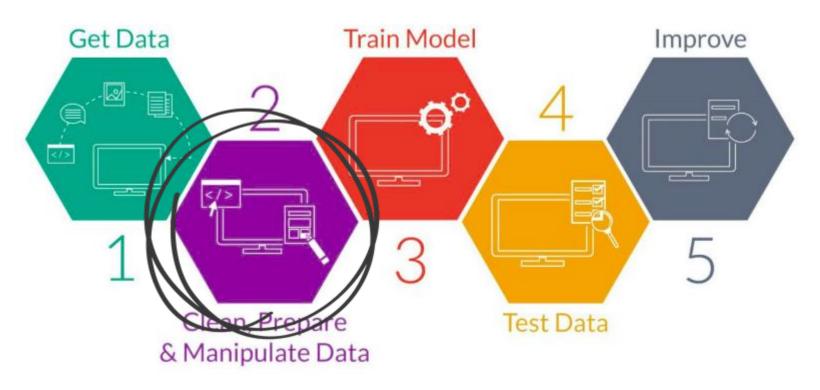
Repetir até conseguir bons resultados



# Tarefas de Aprendizado



### Escopo deste Minicurso



### Descrição dos Dados Utilizados

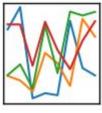
Conjunto de dados com informações sobre os apps disponíveis na Google Play Store Apps, retirado da plataforma kaggle



### **Pandas**

pandas 
$$y_{it} = \beta' x_{it} + \mu_i + \epsilon_{it}$$







Biblioteca open-source em Python que fornece ferramentas de análise de dados e estruturas de dados de alta performance e **fáceis** de usar.

### Ferramentas

- Para a conclusão do minicurso iremos utilizar o Jupyter Notebook;
- Permite a execução de código em células, permitindo um bom uso em tarefas de análise de dados.





## Próximos passos



Podcast: Pizza de Dados







Siraj Raval no YouTube





Obrigado! Dúvidas?







